浙江大学

ZHEJIANG UNIVERSITY

AI 辅助医学图像分类的工程实践
——以 PathMNIST 项目为例

Vibe Coding × Harness Engineering ｜课程第一阶段

汇报人：王张文皓

小组：赵昱淳　李以祺　朱逸枫

从“做一个分类器”到“交付一个可核查项目”

提出任务

课程要求、方向
数据位置、边界

生成与运行

代码与阶段脚本
小测试到正式实验

核验与修正

指标、日志与来源
发现不足再检查

交付与复用

PPT 与系列报告
代码、演示与版本

课程第一阶段产出：数据探索笔记、基线模型、 Vibe × Harness 日志与评估报告。

科研结果保留，但本次主线是 AI 交互、验证与工程交付。

来源： S01 ； 本轮已确认大纲 S20

任务与来源： PathMNIST 九类病理组织图像块

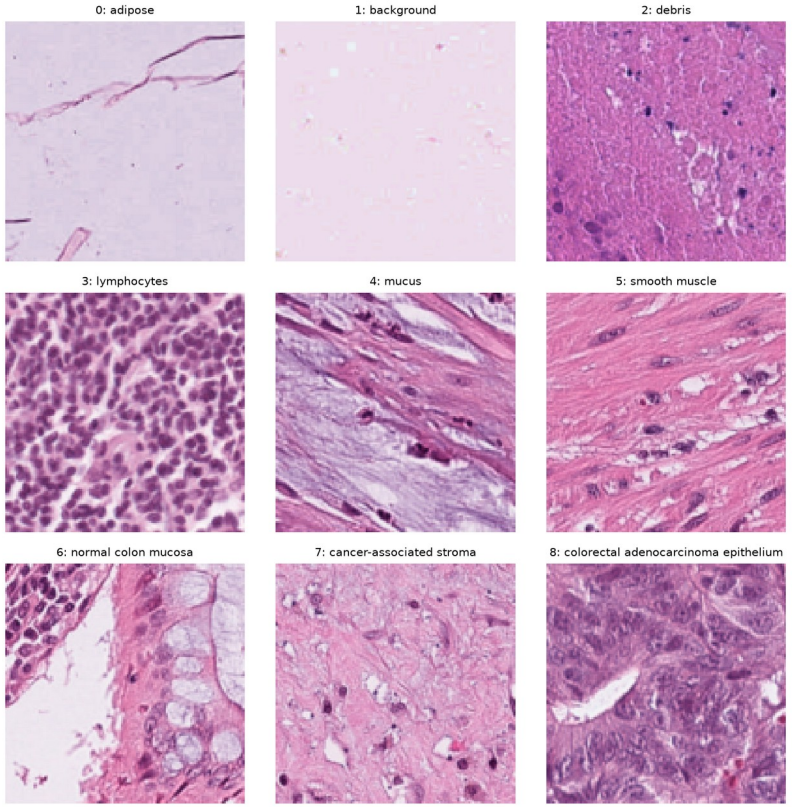
MedMNIST 中的病理分类子集

结直肠 H&E 染色图像块，标签 0—8

开发数据： NCT-CRC-HE-100K

外部测试： CRC-VAL-HE-7K

训练	验证	另一中心测试
89,996	10,004	7,180



采用官方 128×128 版本； 64 输入从同图缩小。图像块数量不是患者数量。

来源： S03–S04 ； stage1/class_counts.csv

协作分工：讨论、执行、审查和决定不混在一起

角色	实际参与	边界
人／小组	提出目标与操作范围；批准继续／停止；真实分工与最终表述	不等于手写或人工复算全部代码
ChatGPT 对话	构思、质询、方案和交接；解释结果；组织文稿与 PPT	建议仍要与当前代码核对
Codex	读仓库、写代码、跑阶段任务和测试、记录与打包	AI 目视检查不等于专家复核
DeepSeek 网页	第六阶段量化风险审查；函数与绘图草稿	没有训练 A—E 或生成实验成绩

工具参与范围按日志记录；未使用 Claude Code 。

来源： S02 、 S08 、 S13–S14 ； 当前对话

整体路线：每一阶段都有任务、产物和放行条件

01 选题与数据

方向、来源与边界

02 环境与协议

清单、矩阵与参数

03 逐级运行

smoke→probe→ 基线

04 正式实验

A—D 再 E，共 15 条

05 核验与评价

审计→冻结→测试

06 部署与交付

ONNX 、文稿与版本

阶段间交接：读已有文件 → 看完成状态 → 处理未决问题 → 再批准下一步

来源： S02； 各阶段执行记录

交互一：把方向和限制写成可执行任务

用户输入（日志节选）

“每一阶段做好记录，最终目的都是为了最后的汇报和报告。”

另有目录、数据位置与禁止覆盖要求。

AI 逐轮拆解为文件

数据 manifest

实验 matrix + 方法协议

HANDOFF + 验收清单

目标	输入与上下文	约束	输出与验收
九类分类与工程实践	课程、源码、已有日志	不改冻结；不重开测试	明确文件与检查方法

来源： S02 原话节选； S03 方法协议； S14 补漏交接

数据与环境：先限制操作，再检查输入

操作范围

只在本人项目目录
数据不在本机整包下载
独立环境与缓存

自动检查

官方文件 MD5
图像形状与标签范围
数量、顺序和索引

阶段产物

manifest 与数据 ID
九类样例和分布图
版本与执行记录

无可靠患者／切片 ID： 像素、文件与索引检查不能证明患者级隔离。

来源： S04； data.py；历史环境与 manifest

把研究问题固定成 A—E ，而不是不断增加模型

组	模型	输入	增强
A	ResNet-18	64×64	开启
B	ResNet-18	128×128	开启
C	MobileNetV3-Small	64×64	开启
D	MobileNetV3-Small	128×128	开启
E	MobileNetV3-Small	128×128	关闭

共同条件

各自 ImageNet V1
九类输出、全网络微调
3 个种子： 42/2026/3407
AdamW ，最多 40 轮
batch128 ，早停 patience8

指定配对控制主要因素；没有全架构海选，也不将三种子称为三折。

来源： S03 ； stage3/matrix.json ； model.py

生成后不是直接全跑：从小到大逐级放行

真实 smoke

144 训练＋ 72 验证

1 轮，训练→保存→重载

最大输入 probe

两种模型 / 128 输入

共同 batch128 可运行

单条正式基线

A_seed42

完整 train/val 与结果复算

分阶段完成矩阵

其余 A—D，再完成 E

总计 15 条正式训练

每条正式运行留下：配置、数据与源码标识、 history 、最佳权重、逐图预测、指标、日志。

smoke 说明流程可通；其分数从不混入正式医学分类结果。

来源： S05–S06； S02 各阶段运行记录

三层核验：自动计算、 AI 审查、人的决定

自动／确定性检查

形状、标签、概率合法性
MD5 / SHA 与来源
从 CSV 重新计算指标
冻结锁与拒绝覆盖

AI 辅助审查

读取源码、日志和图表
指出不一致与风险
给出需要验证的解释
另一 AI 赞同不等于实测

人工评审与决策

研究问题和资源范围
是否采纳、继续或停止
表述边界与提交内容
真实个人贡献待本人确认

哈希一致不等于科学结论正确； AI 看图不等于病理专家复核。

来源： S02 、 S10 、 S13–S14 ； 已有验收记录

先按验证与 CPU 选择演示模型，再统一外部评价

评价指标

Accuracy： 整体正确比例

Macro-F1： 先算九类 F1，再等权平均（主指标）

训练仍优化交叉熵。

1 A—D 验证筛选

距最高组 ⩽ 0.005

2 候选比较 CPU

A/B/D 入围， D 较快

3 D 内选择种子

验证 F1 选 D_seed2026

4 冻结后正式测试

全部 15 条轨迹仍评价

选择的是演示权重，不是只允许一个模型测试。 0.005 是工程容差。

来源： S11 frozen.json； S12 源表

正式结果总览：五组、三种子及外部测试

配置	验证宏 F1	测试宏 F1 ± SD	测试 ACC	CPU / ms
A ResNet / 64	0.9958	0.9059 ± 0.0003	92.70%	10.586
B ResNet / 128	0.9986	0.9094 ± 0.0043	93.19%	12.540
C MobileNet / 64	0.9926	0.8672 ± 0.0091	89.19%	1.679
D MobileNet / 128	0.9978	0.9243 ± 0.0041	94.33%	1.845
E MobileNet / 128 无增强	0.9963	0.9348 ± 0.0076	95.16%	1.851

验证最高： B ｜ 测试最高： E ｜ 测试前冻结的演示模型： D_seed2026

来源： S12 all_runs.csv ； 按保存字段算术汇总

结果一：同一模型从 64 到 128，收益大小不同

ResNet-18

A / 64　0.9059 → B / 128　0.9094

+0.0035

MobileNetV3-Small

C / 64　0.8672 → D / 128　0.9243

+0.0572

128 的组均值更高； ResNet 有一个种子反向，不说每次都提升。

来源： S12； B–A 与 D–C 同种子对照

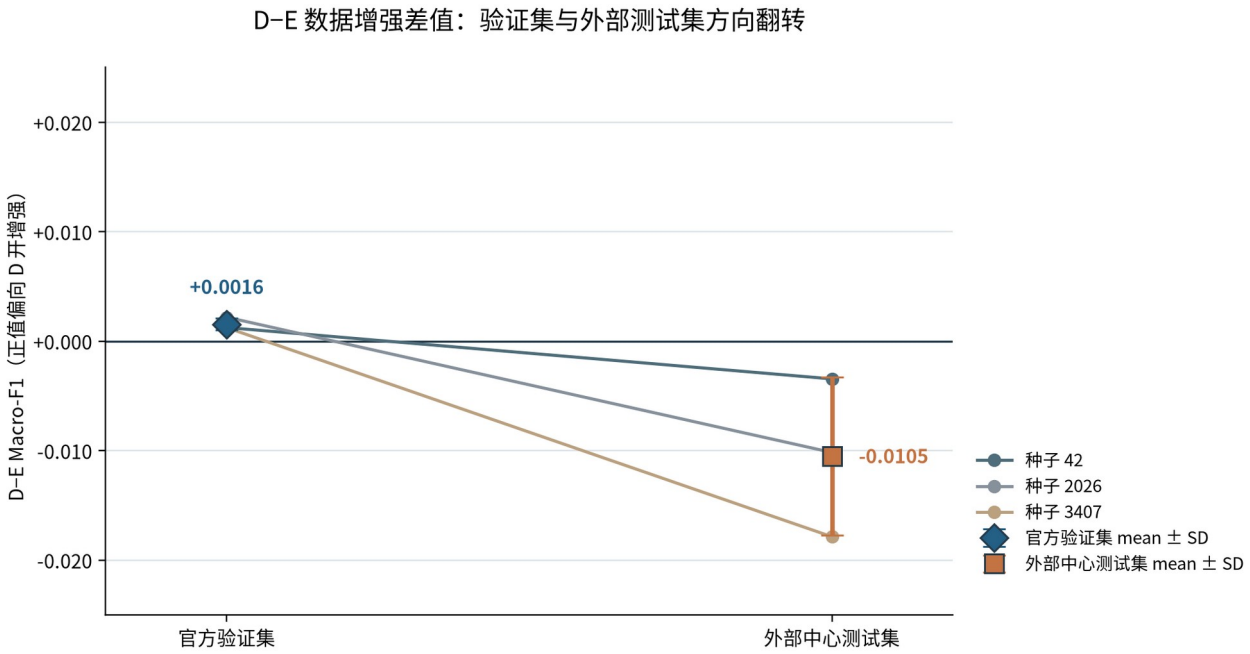
结果二：固定 128 输入， D 兼顾效果和计算开销

比较项	B： ResNet-18 / 128	D： MobileNet / 128
测试 Macro-F1	0.9094	0.9243
九类模型参数	11.18 M	1.53 M
CPU 前向中位延迟组均值	12.540 ms	1.845 ms

共同协议下的模型方案比较；不同预训练配方，不作纯结构因果归因。

来源： S12 ； 统一 PyTorch CPU 基准

结果三：增强的验证优势，没有延续到另一中心



每条细线连接同一种子；D 为开启几何增强，E 为关闭增强；零线表示两组相同。 点/柱为三个训练种子的均值；误差条为种子间样本 SD，不是患者层面置信区间。

D – E

验证： +0.001552

测试：– 0.010498

三个种子的测试方向均为 E 更高。

报告发生了什么；没有把“增强普遍有害”写成结论。

来源： S12 ； 现有 augmentation_direction_flip 图

讨论起点：验证近满分，先让 AI 回到代码与证据

检查计算链条

训练／验证数组是否混用?
验证是否仍增强、更新参数?
预测索引与标签是否错位?
指标能否从逐图 CSV 复算?

相似候选与敏感性

849 对候选，涉及 91 张验证图
排除后 B/D 均值变化 < 0.000003

未发现上述工程错误，
但仍不能证明患者／切片隔离。

讨论位置不改变时间线；高分审计不是测试后才补做。

来源： S07 ； 既有高分审计（实际发生于正式测试前）

案例一： ChatGPT 建议， Codex 核对后才决定采纳

建议／判断（归纳）	Codex 回到当前项目核对	实际处理
“缺少早停”	源码已有 patience=8	否决缺失判断
“需要完整续训”	best.pt 缺完整训练状态	采纳，独立原型验收
“ 40 轮直接接到 200 轮”	余弦计划改变，不是原轨迹延续	未默认执行
“扩展到更多轨迹”	增强参照与原 E 不同	先完成原协议，控制范围

跨会话建议不是执行依据；已有代码与当前状态必须先核对。

来源： S08 实验升级方案审阅记录； S09 恢复原型

案例二： DeepSeek 给出草稿，但没有直接进入正式代码

输入：公开方法概述

说明 train 校准、 val 验收及计时协议；
要求风险清单、函数与绘图草稿；
不假设已经运行本项目。

➡

发现：输入契约不足

标签 0—8 、概率非负、非空样本、
显式固定九类 labels 等检查不完整。

产物	实际决定
指标函数	未采用，沿用已验收 metrics
绘图与风险意见	选择性采纳；修订后先用合成 JSON 验收

原话在日志；页面是归纳。多个 AI 参与，不等于多个独立实验认证。

来源： S13 原始提示与后续审查

案例三：核验脚本报错，不重写正式测试预测

保留原产物

冻结权重与正式预测
不覆盖、不重新测试

➡

定位问题

混淆矩阵 JSON 列表
被核验代码误当对象

➡

最小修复

修正读取类型
只重跑核验程序

➡

再检查

核对已有预测与指标
保留失败与修复记录

另行开发的 resume_v2 与 portable_demo 也使用独立目录，避免改变原训练与冻结结果。

来源： S10 第五阶段记录； S17 工程加固

案例四：量化精度恢复了，仍然可以决定“不替换”

S8S8 / U8U8 验证 F1 约 0.38 → 训练样例诊断 → 预登记五 Conv 保留浮点

版本	验证 Macro-F1	文件 / MiB	CPU 前向 / ms
FP32	0.9981	5.8450	0.422792
混合精度 PTQ	0.9957	1.7596	0.533642

文件缩小约 69.9%，耗时反而增加约 26.2%；候选留档，默认演示仍为 FP32。

来源： S15–S16；同次第七阶段 FP32 对照

部署：原 FP32 就能离线运行，量化不是必要前提

冻结 D_seed2026 → FP32 ONNX

转换模型表示；不重新训练。 ONNX Runtime 在 CPU 上执行。

本地界面与异常处理

图像→相同预处理→九类预测

检查模型哈希、标签、输入、路径和输出防覆盖



历史 Mac 断网记录 ≠ 全平台验收；当前新提交目录的模型与样例还需复制。

来源： S17–S18 ； 原阶段七真实截图

原仓库保留，新教师仓库只服务提交与阅读

原科学与工程仓库

pathmnist-tissue-classification
固定证据： d5e4a71…84d1d
完整阶段历史、模型、数据
本轮只读，不修改

新教师提交仓库（待上传）

pathmnist-ai-practice-submission
PPT 、主报告和三份附件
必要代码、源表与案例原件
独立权限、清楚入口

仅复制必要证据并记来源；新仓库、 Release 、云端 CI 和教师访问需实际完成后确认。

来源： S20 用户决定；当前状态 S21

可复用的是代码与约束，不是虚构的 Skill 清单

已存在的局部工具

数据与训练 CLI
结果复算与冻结检查
resume_v2 独立原型
portable_demo

专用 Skill 的证据边界

没有可追溯的项目专用
local/global Skill 调用记录

脚本或平台能力
不自动等于正式 Skill 包

本轮新增提交检查

JSON/CSV 与哈希
保存指标的算术对照
链接和文稿结构
CI 配置已备，云端待运行

来源： S02 、 S09 、 S17 ； 本轮检查工具 S21

人的学习：会提任务、会质询、会拒绝不合适的建议

实践收获	在本项目中的表现
从目标到任务	明确输入、范围、产物和验收；不只说“帮我做模型”
从结果到证据	区分自动计算、 AI 建议和人工决定；知道哈希的边界
从建议到取舍	早停缺失判断被纠正； DeepSeek 草稿未直接采用
从一次对话到交付	记录版本和未决项，换会话仍能找到依据

没有无 AI 对照或完整工时账本，不编造提效百分比；具体成员贡献由本人填写。

来源： S08 、 S13 、 S20 ； 个人分工待本人确认

总结：留下可运行的产物，也留下可追溯的判断

本项目已经形成

真实任务：五组、三种子的分类实验
可检查结果：源表、预测复核和冻结记录
可复盘交互：建议、失败、修复与采纳状态
可复用内容：源码、离线程序与当前提交材料

保留的限制

图像块，不是患者诊断
未做 K 折、未用 Claude Code
混合精度未取得 CPU 加速
新仓库与云端 CI 尚待发布

AI 实践的重点不是“ AI 说完成”，而是能解释做了什么、怎样检查、为什么这样决定。

来源： S02–S21 ； 完整证据见三份附件与来源索引

谢谢，请老师批评指正

AI 辅助医学图像分类的工程实践

- A1 两种模型怎样分类
- A2 Macro-F1 怎样计算
- A3 数据与统计边界
- A4 AI 与交付常见追问

来源：配套讲稿、主报告与三份附件

两种网络的简化结构：全网络微调，不只是训练末层

两种模型的简化结构

标准 torchvision 网络的机制示意；不展开逐层拓扑，不代表本项目提出了新架构



共同设置：各自 ImageNet V1 预训练权重 → 替换九类输出 → 全网络微调

简化图只表示核心机制；通道重标定并非每个轻量模块都具备。参数量来自正式结果 CSV。

来源： S03； model.py；已有 G01 示意图

返回答疑索引

用癌相关间质的一类结果解释 Macro-F1

真实类别 7 的计数

TP = 263

FP = 15

FN = 158

实际该类 = 421 张

Precision = 263 / 278 = 0.9460

Recall = 263 / 421 = 0.6247

F1 = 526 / 699 = 0.7525

九类 F1 等权平均 = 0.929008

图像块的类别漏判，不是患者漏诊率；训练损失仍是交叉熵。

来源： S12； D_seed2026/test_metrics.json

返回答疑索引

三种容易混淆的“独立”

说法	实际是什么	不能推出什么
三个随机种子	同一划分重复训练	不是三折或患者 CI
不同图像索引	样本位置不同	不是患者／切片来源独立
独立复核脚本	从已有文件重算	不保证没有共同错误假设
测试后 E 更高	当前测试数据的观察	不是事先选中 E 的新盲测

没有可靠分组 ID，仍可技术性随机分折，但不能因此保证患者隔离。

来源：S03、S07、S11–S12；现有评估协议

返回答疑索引

关于 AI 协作和云端交付，可以直接回答的四件事

可能问题	本项目的准确回答
谁核验了结果?	脚本做计算复核； AI 辅助读代码；人的决策与专家判读分开。
DeepSeek 做了什么?	第六阶段网页风险审查和草稿；未训练 A—E 。
用了哪些 Skill ?	有 CLI 和审计模块；无可追溯的项目专用 Skill 调用证据。
新仓库与 CI 完成了吗?	本地材料与配置已准备；云端创建、运行、发布及授权仍待执行。

来源： S02 、 S13–S14 、 S20–S21

返回答疑索引