浙江大学

ZHEJIANG UNIVERSITY

# AI 辅助医学图像分类的工程实践
## ——以 PathMNIST 项目为例

Vibe Coding × Harness Engineering ｜课程第一阶段

汇报人：王张文皓

小组：赵昱淳　李以祺　朱逸枫

# 从“做一个分类器”到“交付一个可核查项目”

**提出任务**

课程要求、方向
数据位置、边界

**生成与运行**

代码与阶段脚本
小测试到正式实验

**核验与修正**

指标、日志与来源
发现不足再检查

**交付与复用**

PPT 与系列报告
代码、演示与版本

课程第一阶段产出：数据探索笔记、基线模型、 Vibe × Harness 日志与评估报告。

**科研结果保留，但本次主线是 AI 交互、验证与工程交付。**

来源： S01 ； 本轮已确认大纲 S20

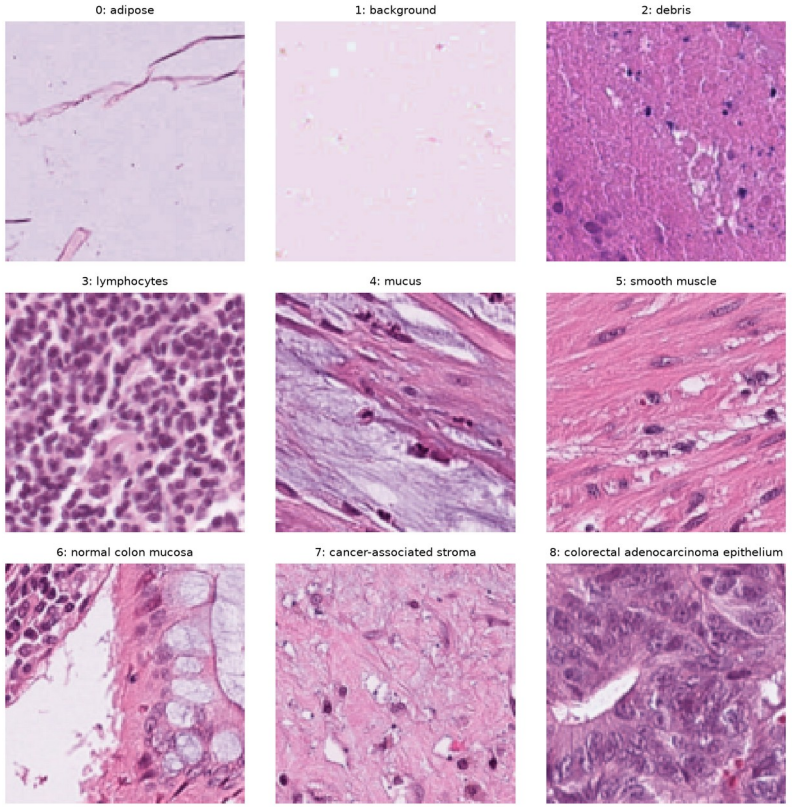
# 任务与来源： PathMNIST 九类病理组织图像块

## MedMNIST 中的病理分类子集
## 结直肠 H&E 染色图像块，标签 0—8

开发数据： NCT-CRC-HE-100K

外部测试： CRC-VAL-HE-7K

| 训练 | 验证 | 另一中心测试 |
| --- | --- | --- |
| 89,996 | 10,004 | 7,180 |




**采用官方 128×128 版本； 64 输入从同图缩小。图像块数量不是患者数量。**

来源： S03–S04 ； stage1/class_counts.csv

# 协作分工：讨论、执行、审查和决定不混在一起

| 角色 | 实际参与 | 边界 |
| --- | --- | --- |
| 人／小组 | 提出目标与操作范围；批准继续／停止；真实分工与最终表述 | 不等于手写或人工复算全部代码 |
| ChatGPT 对话 | 构思、质询、方案和交接；解释结果；组织文稿与 PPT | 建议仍要与当前代码核对 |
| Codex | 读仓库、写代码、跑阶段任务和测试、记录与打包 | AI 目视检查不等于专家复核 |
| DeepSeek 网页 | 第六阶段量化风险审查；函数与绘图草稿 | 没有训练 A—E 或生成实验成绩 |

**工具参与范围按日志记录；未使用 Claude Code 。**

来源： S02 、 S08 、 S13–S14 ； 当前对话

# 整体路线：每一阶段都有任务、产物和放行条件

**01 选题与数据**

方向、来源与边界

**02 环境与协议**

清单、矩阵与参数

**03 逐级运行**

smoke→probe→ 基线

**04 正式实验**

A—D 再 E，共 15 条

**05 核验与评价**

审计→冻结→测试

**06 部署与交付**

ONNX 、文稿与版本

**阶段间交接：读已有文件 → 看完成状态 → 处理未决问题 → 再批准下一步**

来源： S02； 各阶段执行记录

# 交互一：把方向和限制写成可执行任务

## 用户输入（日志节选）

“每一阶段做好记录，最终目的都是为了最后的汇报和报告。”

另有目录、数据位置与禁止覆盖要求。

## AI 逐轮拆解为文件

数据 manifest

实验 matrix + 方法协议

HANDOFF + 验收清单

| 目标 | 输入与上下文 | 约束 | 输出与验收 |
| --- | --- | --- | --- |
| 九类分类与工程实践 | 课程、源码、已有日志 | 不改冻结；不重开测试 | 明确文件与检查方法 |

来源： S02 原话节选； S03 方法协议； S14 补漏交接

# 数据与环境：先限制操作，再检查输入

## 操作范围

只在本人项目目录
数据不在本机整包下载
独立环境与缓存

## 自动检查

官方文件 MD5
图像形状与标签范围
数量、顺序和索引

## 阶段产物

manifest 与数据 ID
九类样例和分布图
版本与执行记录

**无可靠患者／切片 ID： 像素、文件与索引检查不能证明患者级隔离。**

来源： S04； data.py；历史环境与 manifest

# 把研究问题固定成 A—E ，而不是不断增加模型

| 组 | 模型 | 输入 | 增强 |
| --- | --- | --- | --- |
| A | ResNet-18 | 64×64 | 开启 |
| B | ResNet-18 | 128×128 | 开启 |
| C | MobileNetV3-Small | 64×64 | 开启 |
| D | MobileNetV3-Small | 128×128 | 开启 |
| E | MobileNetV3-Small | 128×128 | 关闭 |

## 共同条件

各自 ImageNet V1
九类输出、全网络微调
3 个种子： 42/2026/3407
AdamW ，最多 40 轮
batch128 ，早停 patience8

**指定配对控制主要因素；没有全架构海选，也不将三种子称为三折。**

来源： S03 ； stage3/matrix.json ； model.py

# 生成后不是直接全跑：从小到大逐级放行

### 真实 smoke

144 训练＋ 72 验证

1 轮，训练→保存→重载

### 最大输入 probe

两种模型 / 128 输入

共同 batch128 可运行

### 单条正式基线

A_seed42

完整 train/val 与结果复算

### 分阶段完成矩阵

其余 A—D，再完成 E

总计 15 条正式训练

每条正式运行留下：配置、数据与源码标识、 history 、最佳权重、逐图预测、指标、日志。

**smoke 说明流程可通；其分数从不混入正式医学分类结果。**

来源： S05–S06； S02 各阶段运行记录

# 三层核验：自动计算、 AI 审查、人的决定

## 自动／确定性检查

形状、标签、概率合法性
MD5 / SHA 与来源
从 CSV 重新计算指标
冻结锁与拒绝覆盖

## AI 辅助审查

读取源码、日志和图表
指出不一致与风险
给出需要验证的解释
另一 AI 赞同不等于实测

## 人工评审与决策

研究问题和资源范围
是否采纳、继续或停止
表述边界与提交内容
真实个人贡献待本人确认

**哈希一致不等于科学结论正确； AI 看图不等于病理专家复核。**

来源： S02 、 S10 、 S13–S14 ； 已有验收记录

# 先按验证与 CPU 选择演示模型，再统一外部评价

## 评价指标

Accuracy： 整体正确比例

Macro-F1： 先算九类 F1，再等权平均（主指标）

训练仍优化交叉熵。

**1 A—D 验证筛选**

距最高组 ⩽ 0.005

**2 候选比较 CPU**

A/B/D 入围， D 较快

**3 D 内选择种子**

验证 F1 选 D_seed2026

**4 冻结后正式测试**

全部 15 条轨迹仍评价

**选择的是演示权重，不是只允许一个模型测试。 0.005 是工程容差。**

来源： S11 frozen.json； S12 源表

# 正式结果总览：五组、三种子及外部测试

| 配置 | 验证宏 F1 | 测试宏 F1 ± SD | 测试 ACC | CPU / ms |
|---|---|---|---|---|
| A ResNet / 64 | 0.9958 | 0.9059 ± 0.0003 | 92.70% | 10.586 |
| B ResNet / 128 | 0.9986 | 0.9094 ± 0.0043 | 93.19% | 12.540 |
| C MobileNet / 64 | 0.9926 | 0.8672 ± 0.0091 | 89.19% | 1.679 |
| D MobileNet / 128 | 0.9978 | 0.9243 ± 0.0041 | 94.33% | 1.845 |
| E MobileNet / 128 无增强 | 0.9963 | 0.9348 ± 0.0076 | 95.16% | 1.851 |

**验证最高： B ｜ 测试最高： E ｜ 测试前冻结的演示模型： D_seed2026**

来源： S12 all_runs.csv ； 按保存字段算术汇总

# 结果一：同一模型从 64 到 128，收益大小不同

## ResNet-18

A / 64　0.9059 → B / 128　0.9094

**+0.0035**

## MobileNetV3-Small

C / 64　0.8672 → D / 128　0.9243

**+0.0572**

**128 的组均值更高； ResNet 有一个种子反向，不说每次都提升。**

来源： S12； B–A 与 D–C 同种子对照

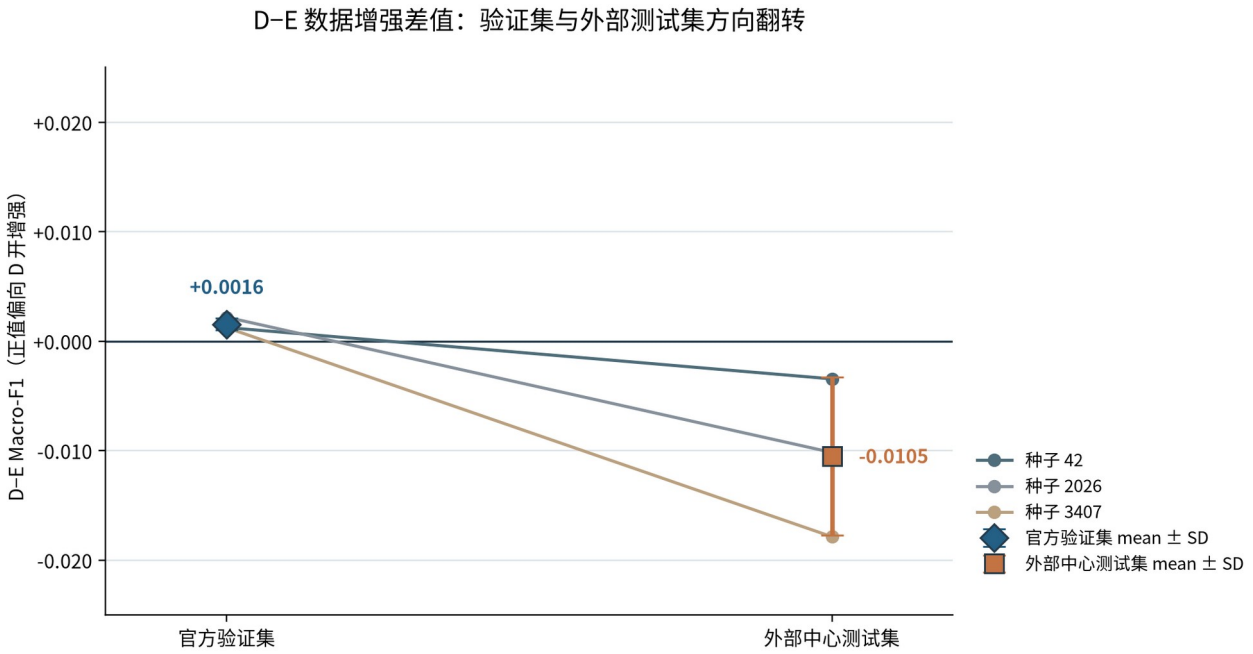
# 结果二：固定 128 输入， D 兼顾效果和计算开销

| 比较项 | B： ResNet-18 / 128 | D： MobileNet / 128 |
| --- | --- | --- |
| 测试 Macro-F1 | 0.9094 | 0.9243 |
| 九类模型参数 | 11.18 M | 1.53 M |
| CPU 前向中位延迟组均值 | 12.540 ms | 1.845 ms |

共同协议下的模型方案比较；不同预训练配方，不作纯结构因果归因。

来源： S12 ； 统一 PyTorch CPU 基准

# 结果三：增强的验证优势，没有延续到另一中心




每条细线连接同一种子；D 为开启几何增强，E 为关闭增强；零线表示两组相同。 点/柱为三个训练种子的均值；误差条为种子间样本 SD，不是患者层面置信区间。

**D – E**

验证： +0.001552

测试：– 0.010498

三个种子的测试方向均为 E 更高。

**报告发生了什么；没有把“增强普遍有害”写成结论。**

来源： S12 ； 现有 augmentation_direction_flip 图

# 讨论起点：验证近满分，先让 AI 回到代码与证据

## 检查计算链条

训练／验证数组是否混用?
验证是否仍增强、更新参数?
预测索引与标签是否错位?
指标能否从逐图 CSV 复算?

## 相似候选与敏感性

849 对候选，涉及 91 张验证图
排除后 B/D 均值变化 < 0.000003

未发现上述工程错误，
但仍不能证明患者／切片隔离。

**讨论位置不改变时间线；高分审计不是测试后才补做。**

来源： S07 ； 既有高分审计（实际发生于正式测试前）

# 案例一： ChatGPT 建议， Codex 核对后才决定采纳

| 建议／判断（归纳） | Codex 回到当前项目核对 | 实际处理 |
| --- | --- | --- |
| “缺少早停” | 源码已有 patience=8 | 否决缺失判断 |
| “需要完整续训” | best.pt 缺完整训练状态 | 采纳，独立原型验收 |
| “40 轮直接接到 200 轮” | 余弦计划改变，不是原轨迹延续 | 未默认执行 |
| “扩展到更多轨迹” | 增强参照与原 E 不同 | 先完成原协议，控制范围 |

**跨会话建议不是执行依据；已有代码与当前状态必须先核对。**

来源： S08 实验升级方案审阅记录； S09 恢复原型

# 案例二： DeepSeek 给出草稿，但没有直接进入正式代码

**输入：公开方法概述**

说明 train 校准、 val 验收及计时协议；
要求风险清单、函数与绘图草稿；
不假设已经运行本项目。

**发现：输入契约不足**

标签 0—8 、概率非负、非空样本、
显式固定九类 labels 等检查不完整。

| 产物 | 实际决定 |
| --- | --- |
| 指标函数 | 未采用，沿用已验收 metrics |
| 绘图与风险意见 | 选择性采纳；修订后先用合成 JSON 验收 |

**原话在日志；页面是归纳。多个 AI 参与，不等于多个独立实验认证。**

来源： S13 原始提示与后续审查

# 案例三：核验脚本报错，不重写正式测试预测

### 保留原产物

冻结权重与正式预测
不覆盖、不重新测试

### 定位问题

混淆矩阵 JSON 列表
被核验代码误当对象

### 最小修复

修正读取类型
只重跑核验程序

### 再检查

核对已有预测与指标
保留失败与修复记录

另行开发的 resume_v2 与 portable_demo 也使用独立目录，避免改变原训练与冻结结果。

来源： S10 第五阶段记录； S17 工程加固

# 案例四：量化精度恢复了，仍然可以决定“不替换”

**S8S8 / U8U8 验证 F1 约 0.38 → 训练样例诊断 → 预登记五 Conv 保留浮点**

| 版本 | 验证 Macro-F1 | 文件 / MiB | CPU 前向 / ms |
| --- | --- | --- | --- |
| FP32 | 0.9981 | 5.8450 | 0.422792 |
| 混合精度 PTQ | 0.9957 | 1.7596 | 0.533642 |

**文件缩小约 69.9%，耗时反而增加约 26.2%；候选留档，默认演示仍为 FP32。**

来源： S15–S16；同次第七阶段 FP32 对照

# 部署：原 FP32 就能离线运行，量化不是必要前提

## 冻结 D_seed2026 → FP32 ONNX

转换模型表示；不重新训练。 ONNX Runtime 在 CPU 上执行。

## 本地界面与异常处理

图像→相同预处理→九类预测

检查模型哈希、标签、输入、路径和输出防覆盖




**11 项原资产已补齐并核哈希；新副本 Mac 验收通过，课堂设备尚待检查。**

来源： S17–S18 历史截图； S21 新副本验收

# 原仓库保留，新教师仓库只服务提交与阅读

## 原科学与工程仓库

pathmnist-tissue-classification
固定证据： d5e4a71…84d1d
完整阶段历史、模型、数据
本轮只读，不修改

## 新教师提交仓库（已上传）

pathmnist-ai-practice-submission
PPT 、主报告和三份附件
必要代码、源表与案例原件
独立权限、清楚入口

**独立私有库和 CI 已完成；运行资产在新库可取，教师账号权限尚待确认。**

来源： S20 用户决定；当前状态 S21

# 可复用的是代码与约束，不是虚构的 Skill 清单

## 已存在的局部工具

数据与训练 CLI
结果复算与冻结检查
resume_v2 独立原型
portable_demo

## 专用 Skill 的证据边界

没有可追溯的项目专用
local/global Skill 调用记录

脚本或平台能力
不自动等于正式 Skill 包

## 本轮新增提交检查

JSON/CSV 与哈希
保存指标的算术对照
链接和文稿结构
云端 CI 已通过，仅查文件与算术

来源： S02 、 S09 、 S17 ； 本轮检查工具 S21

# 人的学习：会提任务、会质询、会拒绝不合适的建议

| 实践收获 | 在本项目中的表现 |
| --- | --- |
| 从目标到任务 | 明确输入、范围、产物和验收；不只说“帮我做模型” |
| 从结果到证据 | 区分自动计算、 AI 建议和人工决定；知道哈希的边界 |
| 从建议到取舍 | 早停缺失判断被纠正； DeepSeek 草稿未直接采用 |
| 从一次对话到交付 | 记录版本和未决项，换会话仍能找到依据 |

没有无 AI 对照或完整工时账本，不编造提效百分比；具体成员贡献由本人填写。

来源： S08 、 S13 、 S20 ； 个人分工待本人确认

# 总结：留下可运行的产物，也留下可追溯的判断

## 本项目已经形成

真实任务：五组、三种子的分类实验
可检查结果：源表、预测复核和冻结记录
可复盘交互：建议、失败、修复与采纳状态
可复用内容：源码、离线程序与当前提交材料

## 保留的限制

图像块，不是患者诊断
未做 K 折、未用 Claude Code
混合精度未取得 CPU 加速
教师权限与课堂设备尚待确认

**AI 实践的重点不是“ AI 说完成”，而是能解释做了什么、怎样检查、为什么这样决定。**

来源： S02–S21 ； 完整证据见三份附件与来源索引

# 谢谢，请老师批评指正

## AI 辅助医学图像分类的工程实践

- A1 两种模型怎样分类
- A2 Macro-F1 怎样计算
- A3 数据与统计边界
- A4 AI 与交付常见追问

来源：配套讲稿、主报告与三份附件

# 两种网络的简化结构：全网络微调，不只是训练末层

## 两种模型的简化结构

标准 torchvision 网络的机制示意；不展开逐层拓扑，不代表本项目提出了新架构




共同设置：各自 ImageNet V1 预训练权重 → 替换九类输出 → 全网络微调

简化图只表示核心机制；通道重标定并非每个轻量模块都具备。参数量来自正式结果 CSV。

来源： S03； model.py；已有 G01 示意图

返回答疑索引

# 用癌相关间质的一类结果解释 Macro-F1

### 真实类别 7 的计数

TP = 263

FP = 15

FN = 158

实际该类 = 421 张

Precision = 263 / 278 = 0.9460

Recall = 263 / 421 = 0.6247

F1 = 526 / 699 = 0.7525

九类 F1 等权平均 = 0.929008

**图像块的类别漏判，不是患者漏诊率；训练损失仍是交叉熵。**

来源： S12； D_seed2026/test_metrics.json

返回答疑索引

# 三种容易混淆的“独立”

| 说法 | 实际是什么 | 不能推出什么 |
| --- | --- | --- |
| 三个随机种子 | 同一划分重复训练 | 不是三折或患者 CI |
| 不同图像索引 | 样本位置不同 | 不是患者／切片来源独立 |
| 独立复核脚本 | 从已有文件重算 | 不保证没有共同错误假设 |
| 测试后 E 更高 | 当前测试数据的观察 | 不是事先选中 E 的新盲测 |

**没有可靠分组 ID，仍可技术性随机分折，但不能因此保证患者隔离。**

来源：S03、S07、S11–S12；现有评估协议

返回答疑索引

# 关于 AI 协作和云端交付，可以直接回答的四件事

| 可能问题 | 本项目的准确回答 |
| --- | --- |
| 谁核验了结果? | 脚本做计算复核； AI 辅助读代码；人的决策与专家判读分开。 |
| DeepSeek 做了什么? | 第六阶段网页风险审查和草稿；未训练 A—E 。 |
| 用了哪些 Skill ? | 有 CLI 和审计模块；无可追溯的项目专用 Skill 调用证据。 |
| 新仓库与 CI 完成了吗? | 本地材料与配置已准备；云端创建、运行、发布及授权仍待执行。 |

来源： S02 、 S13–S14 、 S20–S21

返回答疑索引