课程第一阶段 · AI 工程实践主报告

AI 辅助医学图像分类的工程实践

以 PathMNIST 项目为例

Vibe Coding × Harness Engineering：需求拆解、代码执行、结果核验与交付

项目	说明
课程	研究生工程实践（秋学期）
汇报人	王张文皓（12615035）
小组成员	赵昱淳（12615027）、李以祺（22615003）、朱逸枫（12615026）
学号与个人分工	代码实现：王张文皓；规划：赵昱淳；测试整理：李以祺；云端报告：朱逸枫
实际提交日期	待填写
科学证据	原项目固定提交 d5e4a71...84d1d
本文定位	已有项目的 AI 实践重组；不产生新的模型实验

项目技术任务。 使用结直肠病理图像块完成九类组织分类，并比较模型方案、输入尺寸和几何增强。模型是现成架构，不是本组提出的新网络。[S03]

本次报告重点。 说明人与 ChatGPT、Codex、DeepSeek 如何分工，怎样从自然语言任务走向可运行代码，怎样检查、修复并保存证据。分类结果是过程的产物，不作为 AI 比人工开发更有效的因果证明。[S02、S20]

本提交仅为图像块分类的课程实践，不包括患者诊断、整张切片分析或课程第二阶段的树莓派 ECG 系统。

摘要与阅读导航

本项目以 PathMNIST 九类病理图像块分类为载体，实践课程提出的“需求—生成—运行—测试—评估—评审—回滚”流程。用户通过多轮对话说明方向、数据位置、实验范围和停止条件；ChatGPT 参与方案讨论、交接与内容解释；Codex 读取项目、编写并运行代码、生成阶段记录和核验材料；DeepSeek 在第六阶段对量化方案作风险审查，生成指标和绘图草稿。各工具的参与范围由相应记录支持，不把一份概述或建议写成已执行实验。[S01–S02、S08、S13–S14]

执行采用逐级扩大范围的方式：先核对数据与环境，再进行真实小样本训练与重载、最大输入下的批量可行性检查和单个正式基线，随后完成 A—E 五组、每组三种子的十五条正式训练。项目记录了数据清单、代码与权重标识、逐轮历史和逐图预测，利用脚本复算指标，辅以 AI 源码审查和人的范围决策。验证近满分引出了高分审计，正式评价之前按验证分数与 CPU 开销选定 D_seed2026 并冻结；没有根据测试后 E 更高的结果回头改变本轮选择。[S04–S12]

工程迭代中，ChatGPT 升级建议与当前源码存在不一致，Codex 核对后只采纳适用部分；DeepSeek 指标草稿因输入契约检查不足未直接使用；初始量化出现严重精度退化，第七阶段有限的混合精度干预将验证 Macro-F1 恢复至 0.995668，但同次 CPU 前向更慢，默认演示继续采用 FP32 ONNX。[S08、S13、S15–S18]

项目最终形成模型与评价记录、数据探索、AI 使用日志、离线演示及版本化材料。本文将自动计算、AI 辅助审查、人工决策和设备验收分层说明；缺少患者／切片 ID、仅一个外部中心、没有无 AI 开发对照，以及若干课程覆盖差异仍然保留。2026 年 10 月 19 日已发布独立教师仓库，补齐原演示资产、验收新副本并通过真实 CI；按小组决定公开，无需账号邀请。[S20–S21]

关键词：AI 辅助编程；Vibe Coding；Harness Engineering；PathMNIST；结果核验；工程交付

阅读方式

第 1—3 章说明任务和执行过程，第 4—5 章重点说明核验与交互，第 6 章给出实际结果，第 7—8 章说明复用和反思。数据细节、交互原文和完整模型评估分别见三份附件。文中[S 编号]见文末来源导航；每项历史“通过”均指其原始记录，不冒称本轮重跑。

1 课程任务与项目目标

1.1 从课程要求确定实践重点

课程第一阶段允许从公开医学或生理数据库中选择一个识别任务，借助 AI 完成基线模型，并提交数据集探索笔记、Vibe × Harness 使用日志与评估报告。医学图像条目包括分类、迁移学习、量化后离线推理，以及形状、标签、增强和指标检查。课程并非只要求最终取得一个较高准确率。[S01]

因此，项目有两条同时存在的目标：技术上完成可以评价的组织分类任务；学习上掌握如何给 AI 提供上下文、拆解任务、执行小测试、解释输出、处理错误并保存可追溯成果。二者不能互相替代：只有工作流而没有真实产物不完整，只有高分而没有 AI 交互与核查过程也不符合本次汇报重点。

1.2 为什么选择医学图像与 PathMNIST

早期 AI 日志记载，用户选择医学图像方向，将具体子集交由助手推荐；随后采用 PathMNIST。课程资料本身列有 MedMNIST 系列，任务标签、文件格式和官方划分适合建立有限规模的分类基线。这里能说明的是选择过程和任务适配性，没有记录多个数据集的训练海选，因此不补写不存在的数据集排名。[S01–S04]

PathMNIST 提供结直肠 H&E 病理图像块及九种组织标签。本项目读取官方 128 像素版本；同一张图像缩小至 64 像素用于尺寸对照。训练、验证和测试分别为 89,996、10,004 和 7,180 张。前两份来自同一开发来源，测试来自另一中心。原始来源名称与项目划分角色分开：CRC-VAL-HE-7K 在本项目中是测试集，并非早停使用的验证集。[S03–S04]

1.3 实验范围与未覆盖内容

网络选择限定为 ResNet-18 和 MobileNetV3-Small，不搜索全部架构。A—D 构成两种模型与两种尺寸的对照；E 只关闭 D 的整套几何增强。每组三种子用于观察固定划分下的训练波动。十五次正式训练不包含 smoke、恢复短轨迹或量化校准。[S03、S05–S06]

本项目不具备患者级诊断、患者级分组交叉验证或临床有效性证据。原 NPZ 缺少可靠患者／切片标识，不能把图像索引当作患者 ID。课程第二阶段的硬件采集和端云系统也不在本件已完成范围内。[S01、S04]

2 人与 AI 工具的协作组织

2.1 分工不是工具排行榜

角色	实际承担的工作	需要保留的界限
用户／小组	提出方向、服务器和目录约束；讨论范围；决定继续或停止；核对最终提交与真实贡献	不据此声称手写或逐项人工复算了全部代码和结果
ChatGPT 对话	方案讨论、质询与解释，形成交接文件；审阅材料和组织报告、PPT	并非每次讨论都能访问现场代码；建议必须回到实际项目核对
Codex	读取仓库、编写脚本与测试、服务器执行、阶段记录、复算和部署加固	自动核验与 AI 目视检查不能冒充病理专家复核
DeepSeek 网页	第六阶段量化风险审查、指标与绘图草稿	未参与 A—E 训练；其回复不是实测数据或第三方认证

以上为工作类型归纳，具体发生时间以各阶段 AI 日志为准。没有使用 Claude Code，也没有通过 Claude Code 路由接入 DeepSeek 的证据。[S02、S08、S13–S14]

2.2 交互通过材料衔接，而不是依赖 AI“记得”

项目并非一次提示自动完成。阶段之间用方法协议、运行摘要、HANDOFF、验收清单和已有文件传递上下文。任务文档说明要读什么、允许改什么、禁止动什么、应产生什么文件，以及用什么检查放行。用户要求“每一阶段做好记录，最终用于汇报和报告”，因此留档不是最后补写，而是阶段工作的一部分。[S02、S14]

源码和日志与对话建议冲突时，先核对项目事实。比如升级建议曾把早停列为不足，但当前代码已有早停；Codex 通过源码审阅识别了这一差异。交接文档的作用是减少信息丢失，不是替代事实核对。[S08]

2.3 人的责任怎样体现

人的责任主要表现为目标和风险取舍：指定只操作本人项目目录、批准阶段推进、决定不盲目增加模型与轮数、接受未解决的数据限制，并确认报告能表达什么。某条日志只写“人工修订”而没有姓名时，本报告不把它归给某位组员。成员分工已由小组补充，见第 8.3 节；未署名的历史操作仍不逐项归给个人。[S02、S14、S20]

2.4 Vibe 与 Harness 在项目中的具体含义

课程材料将 Vibe Coding 解释为自然语言驱动、执行反馈与人机协作；将 Harness Engineering 解释为可验证、可回滚、可审计的工程约束。本文沿用课程的操作性定义，不扩展为关于所有 AI 编程方式的普遍结论。[S01]

环节	本项目怎样做	留下什么
描述需求	说明医学图像任务、数据位置、范围及禁止事项	用户任务与阶段交接
AI 拆解	拆成数据、实验配置、运行步骤与验收要求	协议、矩阵和清单
生成并执行	编写代码后先进行小范围检查，再扩大	命令、日志、退出码、产物
读取反馈	对照报错、指标、图表及冻结来源	审查结论与问题记录
修正与再验收	只改相关部分；必要时独立目录实现	新检查结果、旧件保护记录
交付	报告、演示、源表、下载与版本导航	可阅读、可核对的文件集合

Vibe 与 Harness 不是前后互斥的两个阶段。生成代码时就需要约束输入和输出；运行时要记录状态；反馈修正后要重新检查相关功能。一个 AI 生成、另一个 AI 赞同，并不自动构成确定性验证。[S02、S13–S14]

任务描述的实际改善

早期自然语言给出方向和阶段要求，后来的补漏交接更明确地规定：不重训、不重跑官方测试、不改冻结；取回已有证据，开发独立 FP32 演示，并验收异常输入与断网条件。这种变化体现了交互从“请帮我完成任务”逐步转为“在明确边界内交付可核对产物”。[S14]

这里没有完整的工时或 token 对照，不能由交互方式的变化推算节省了多少时间。能确认的是任务、检查和产物之间的联系更明确，而不是量化的效率提升。

3 从选题到实验完成的全过程

3.1 数据与环境：先限制操作范围，再生成实现

用户确定医学图像方向后，AI 推荐并解释 PathMNIST；数据准备阶段，用户又限定只在本人服务器项目目录操作，不在本机下载完整数据，并避免干扰其他项目。Codex 据此建立独立环境、下载官方数据、核对 MD5，生成类别计数、样例图和数据清单。后续训练和冻结使用同一数据标识。[S02、S04]

这一阶段的产物不是模型分数，而是能够被后续代码可靠读取的数据及其身份记录。跨集合完全像素重复为零，但检查没有提供患者 ID，因此没有将“文件正确”扩大为“患者完全隔离”。用户的目录约束控制操作范围，脚本的形状、计数和哈希检查则控制输入质量。

3.2 从自然语言到固定协议

项目通过多轮沟通把问题落实为两种模型、两档尺寸和一组增强消融。两种网络使用各自 ImageNet V1 权重，替换九类输出层并全网络微调。训练采用共同配置，主指标为验证 Macro-F1。这里是代表性模型方案的比较，不是先通过小样本选出全局最优模型。[S03]

固化对象	意义	不能替代什么
数据 manifest	指明同一份数据、标签和有效索引	不替代来源与患者独立性解释
实验 matrix	明确 A—E、种子、尺寸和共同训练设置	不等于每个网络已最优调参
source_id	识别正式源码版本	不单独证明实现没有错误
方法协议	明确验证、选模、测试和报告口径	后续仍需检查实际执行是否相符

这些文件是把讨论转成可执行约束的产物；没有记录的候选或步骤，不补写成完整的预注册模型搜索。

3.3 逐级执行：从 smoke 到十五条正式轨迹

顺序	实际工作	通过后为什么能进入下一步
真实小样本 smoke	144 张训练、72 张验证，一轮；检查训练、保存与重载	说明关键数据流可以贯通，不用于报告分类效果
最大输入 probe	两种网络在 128 输入下测试 batch；128 可完成前向、反向和优化器步进	提供共同可用批量，不证明最优分类精度或吞吐
单次正式基线	A_seed42 使用完整 train/val；40 轮中第 35 轮最佳	留下首条完整正式轨迹及独立指标复核
主对照扩展	阶段脚本完成其余 11 条 A—D 轨迹	同一协议下形成四组、三种子的比较
E 组消融	原配置关闭几何增强，运行三个种子	补齐原定增强比较，正式总数达到 15

阶段记录给出了实际入口与脚本；“批量执行”是概括，不写成一条 run-matrix 命令一次性完成全部历史工作。[S05–S06、S02]

为什么每次运行都留文件

训练过程中记录配置、数据和源码身份、逐轮历史、最佳权重、验证预测、指标与运行状态。它们支持不同问题的核查：history 解释实际轮次，run 配置解释参数，预测 CSV 支持复算，checkpoint 与冻结记录绑定模型来源。日志和退出码帮助区分启动、运行结束与验收通过。[S05–S06]

原训练程序已有验证早停，最多 40 轮、连续 8 轮不改善则停止。它主要保存最佳权重，不具备完整状态恢复；完整续训后来在独立 resume_v2 原型中实现和验收，没有替换已完成的正式训练。这避免把新工程功能倒写成原 15 条轨迹已经使用。[S08–S09]

3.4 从高分质询到冻结评价

A—D 验证分数接近满分后，项目没有立即宣称模型完美，而是增加只读管线审计、近重复候选筛查和敏感性复算。没有发现训练验证数组混用、验证随机增强、标签错位或指标误算；候选图像不能被定性为患者泄漏。相关审计发生在正式测试之前。[S07]

项目随后确定停止继续扩大模型和长训练范围。冻结选择只看 A—D 的验证组均值：距最高组不超过 0.005 的配置进入候选，比较统一 CPU 开销，再在选中组内按验证 F1 选一份权重。最终演示模型为 D_seed2026。E 作为预定消融，不参与本轮演示配置选择。[S10–S11]

冻结后统一评价全部 15 条预定轨迹，保留所有测试结果。测试中 E 组均值高于 D，没有因此改写选择规则。修复核验脚本时也只重新运行核验，不重新生成正式测试预测。这里体现的约束不只是“禁止更新测试权重”，还包括不根据已见测试成绩重新定义本轮胜者。[S10]

3.5 测试后的分析、部署与文稿

正式测试之后，项目使用已存预测进行 D/E 逐类差异与置信度统计；这些是描述性分析，不倒写成事前假设，也不据此选择新的拒识阈值。工程上继续导出 FP32 ONNX、试验量化、完善独立演示和材料。第七阶段补齐轻量证据与运行验收记录，不重训 A—E。[S14–S18]

报告和 PPT 经过多轮调整，从以分类结果为主转为 AI 实践主线。这属于提交材料的新版本，不更改实验日期或结果。原科学仓库作为来源保留；另建教师提交目录，是对用户最后确认的交付范围的执行。[S20]

4 自动核验、AI 审查与人工评审

4.1 按检查方法分层，而不只按工具名称分层

层次	典型对象与方法	执行与来源	结论范围
自动／确定性检查	形状、标签、概率、哈希、指标复算、冻结文件	程序执行；可由 Codex 生成或调用	在定义条件下数据与计算一致
AI 辅助审查	阅读源码、日志、图表，发现不一致与提出风险	Codex、独立审查代理、阶段性 DeepSeek	形成待核对意见，不是新的实测结果
人的评审与决策	范围、路径、预算、是否采纳和报告表述	用户确认和小组真实记录	决定下一步与承担提交责任

一个由 AI 编写的脚本，真正执行后产生的复算结果，属于自动检查；不能因为脚本作者是 AI，就与 AI 语言上的“认为正确”混为一类。反过来，即使独立代理复算一致，也可能与原脚本共享错误假设，因此仍需要清楚的指标定义和输入契约。[S02、S13–S14]

4.2 核验的最小记录单位

一项“通过”至少对应检查对象、方法、实际输入、代码或环境版本、执行结果、来源文件和限制。比如“验证指标复算通过”需要说明读取哪份预测 CSV、检查多少行、怎样固定九类标签，而不能只截取绿色 passed 一词。不同阶段的测试数可能有重叠，不简单相加为一次独立测试总数。

第七阶段留有 30 份正式预测的复核汇总，但本轮写作没有重新从 30 份完整概率 CSV 计算全部 AUC。文稿所用的组均值和混淆矩阵算术检查，与历史完整概率级复核分开记录。[S17、S21]

4.3 “检查通过”不等于什么

记录	可以说	不可以据此说
文件 SHA 一致	本地副本与指定来源字节一致	模型临床有效、科学解释正确
精确重复为零	未发现逐像素完全相同的跨集合图像	已排除同患者、邻近块或变换图关联
静态结构检查	文件／代码满足检查器覆盖的条件	模型已经在真实设备运行
合成输入通过	已构造输入上的程序行为符合预期	合成数据分数是正式医学实验成绩
固定真实样例推理	特定模型与样例可运行，输出与参考匹配	已评价全部真实使用场景
Mac 断网记录	所记环境已完成依赖后的断网演示	断网安装、Windows/Linux 或投影均已通过
三种子均值和 SD	固定划分下的训练结果与波动	患者置信区间或临床显著性

主报告保留这一表格，是为了让教师能够区分项目真正具备的证据层次，而不是把所有“验证”合并成一句结论。[S04、S07、S09、S14、S17–S18]

人工复核的真实状态

历史记录中的一些图表由 Codex 目视检查，不能称为病理专家人工复核。成员、学号与责任范围已由小组补充；未留记录的操作仍不虚构署名。用户决定以可打开的 PPT 提交，不要求现场投影验收。医学解释没有专家证据时只描述数据标签与模型混淆，不依据病理图像外观改写真实标签。[S02、S14、S20]

4.4 发布接手的分层验收

发布接手的验收对象是教师提交副本，不是重新评价正式模型。下表分别列出资产、运行、界面、检查器、云端与获取证据；各层检查不能相加为“医学验证总数”。

层次	2026 年 10 月 19 日记录	可以说明	结论边界
运行资产	1 个 FP32 ONNX 与 10 张固定验证 PNG，共 11 份；复制后逐个核对哈希	基本演示原件已进入新库	没有重训、重导出或迁移完整数据集
新副本运行	独立 Mac arm64 新目录；20 项运行及格式、异常、文件保护检查	所列环境与输入下行为符合预期	不是 20 个病例或新的外部测试成绩
浏览器用例	4 项：正确、不一致、有效上传、损坏上传；3 次真实验证样例前向	所列页面流程可执行	不是 4 个新测试集，也不是浏览器全局断网
检查器测试	21 项合成及边界单元测试	提交检查器的所列行为通过	不是分类网络的新实验成绩
GitHub Actions	运行检查器测试及严格文件、保存结果算术检查	指定提交的云端质量门通过	没有在云端训练、加载模型或建立推理服务
对外获取	公开库及 Release；匿名下载后核对附件哈希	外部读者无需原私有库权限获取材料	不证明临床使用或独立复现实验

命令行运行验收由操作系统限制外网。浏览器用例中，应用仅允许本机回环访问，浏览器本身未全局断网。依赖安装与断网运行也属于不同环节。[S21–S22]

依据为运行资产复制表、新副本运行 JSON、浏览器回执与云端记录。2026 年 10 月 19 日的真实 CI 以指定提交和运行链接为准；本次文稿同步不重新执行模型验收。[S21–S22]

5 典型交互与问题修复

5.1 ChatGPT 升级建议为何没有全部执行

交互背景。 用户将另一段 ChatGPT 方案及两份建议文档交给 Codex，要求先核对项目已完成内容，再评估是否采用。建议涉及早停、断点恢复、200—300 轮和更多训练轨迹。[S08]

建议或判断	Codex 对当前源码的核对	实际取舍
缺少自动早停	不成立；已有验证 F1 和 patience=8	保留原实现，不重复“补早停”
缺少完整续训	成立；best.pt 缺优化器、调度器、随机状态	独立实现恢复原型并小范围验收
原 40 轮直接续到 200 轮	学习率轨迹改变，不能称原轨迹精确延续	新预算若执行需独立协议；没有默认开跑
追加最多 28 条轨迹	属于建议预算；增强参照与原 E 组不一致	先完成原 E，再决定范围；没有照单全收

实际产物。 一份源码审阅记录、一套独立 resume_v2 原型和历史恢复核验记录，而不是 28 条新正式实验。恢复检查比较了连续 4 轮与 2 轮后恢复的短轨迹，24 项状态检查一致；这只证明所检查的工程恢复行为，不提供新的正式医学分类成绩。[S08–S09]

实践收获。 跨会话建议会遗漏代码现状。任务交接必须包含当前实现和完成状态；让执行代理先读取，再判断，优于仅依据建议稿扩大任务。原始建议并非因出自 ChatGPT 就必须采用。

5.2 DeepSeek 提供另一份意见，但草稿仍需审查

第六阶段实际使用已登录 DeepSeek 网页，发送公开方法概述，要求审查冻结后 PTQ 方案，并给出概率对比函数和绘图草稿。没有向该对话提交完整源码、原始图像、逐图预测或服务器凭据。原提示与回复摘要保存在阶段记录中。[S13]

原提示节选：

请只依据上述公开方法信息回答，不假设你已运行该项目。

这条约束避免把语言审查误当远程实验。DeepSeek 指出校准与验收分工、数值退化、延迟可比性、概率接口和逐类退化等风险。它的指标函数却没有完整检查非空样本、0—8 标签、概率非负和固定九类 labels。因此该函数没有直接进入正式管线；项目继续使用既有指标实现。[S13]

绘图草稿属于另一项产物。它经过协议校验、数值标签位置、字体和非法输入处理等修改，先使用合成 JSON 检查脚本，再用实际量化汇总生成结果图。合成图的数值不进入科研结果。不能把“建议被采用了一部分”改写成“DeepSeek 开发并验证了整个项目”。[S13]

交互点	用来约束 AI 的做法
提供上下文	给出任务、输入、已使用测试集、允许的 train/val 角色
明确输出	限定风险数量、函数接口、图表字段和文件格式
指定禁止项	不假设已运行、不建议用测试调参、不编造结果
审查后采纳	风险建议参考；指标草稿不采用；绘图修订后使用

原日志未把“人工审查”署名到个人，本报告也不替任何成员认领。成员责任范围已由小组补充。

5.3 量化失败后的有限干预与不替换决定

初始 S8S8、U8U8 验证 Macro-F1 分别约 0.3755、0.3935，程序虽生成模型，效果却严重退化。第七阶段在不重训、不使用官方测试的限制下，用训练样例调查中间误差，并预先登记一个有针对性的候选：保留早期五个指定 Conv 为浮点。[S15]

诊断过程中也发现调试助手自身对 uint8 计算可能回绕的问题，之后通过类型提升与反量化对照复核。它是诊断辅助计算的问题，不能被写成已经找到了 ONNX 真实推理失败的唯一根因。最初 reader 接口、基线路径与记录字段错误的失败日志也被保留。[S15]

同次第七阶段对照	FP32	混合精度 PTQ
验证 Macro-F1	0.998073	0.995668
模型大小	5.8450 MiB	1.7596 MiB
CPU 前向中位延迟	0.422792 ms	0.533642 ms

候选通过项目预设验证精度门槛，文件缩小约 69.9%，但前向耗时增加约 26.2%，且没有新的外部测试。实际处理是保留候选，默认演示继续使用 FP32。没有为了把量化写成成功加速而删除失败记录或改换计时基线。[S16]

这个案例展示三种不同判断。 程序能生成模型，是运行层面；验证精度达到门槛，是工程验收层面；是否替换默认版本，要结合速度、大小、证据和使用目标。AI 能够辅助每一步，但不能用一条高分替代整个取舍。

6 实际产物与实验结果

6.1 实验是 AI 工作流的产物，不是 AI 效益的对照试验

十五条正式轨迹均有保存结果。以下为三种子组均值，测试 Macro-F1 的±为样本标准差；未进行患者置信区间估计。[S12]

配置	验证 F1 均值	测试 F1 均值±SD	测试 Accuracy	CPU 前向组均值
A ResNet-18／64	0.995818	0.905852±0.000286	92.70%	10.586 ms
B ResNet-18／128	0.998599	0.909398±0.004295	93.19%	12.540 ms
C MobileNet／64	0.992592	0.867163±0.009064	89.19%	1.679 ms
D MobileNet／128	0.997821	0.924315±0.004119	94.33%	1.845 ms
E D 关闭增强	0.996269	0.934814±0.007555	95.16%	1.851 ms

输入尺寸比较中，B−A 约+0.0035，D−C 约+0.0572；提高尺寸的组均收益依赖模型。固定 128 输入，D 对 B 同时获得较高测试 F1 和较低服务器 CPU 前向开销。D−E 在验证为+0.001552，在测试为−0.010498，说明同中心验证收益没有延续到当前外部中心。[S12]

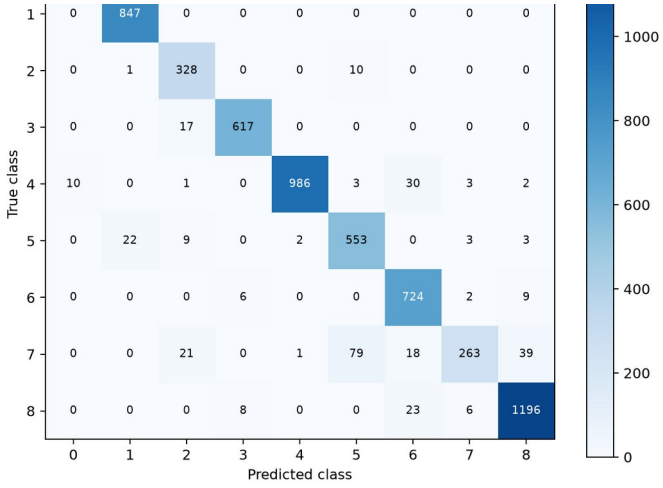
上述数字说明项目确实形成了可评价的模型结果，不证明 AI 辅助比人工开发更快、成本更低或精度更高。项目没有无 AI 对照和完整工时账本，不能据此报告百分比效率收益。

6.2 AI 如何帮助整理讨论

AI 帮助从保存的源表定位差值、检查统计口径、生成图表和解释术语。讨论保留“已观察到什么”与“为什么发生”之间的差别。跨中心下降可观察，但没有证据分离染色、采样、类别构成与过拟合各自的贡献；增强反转可观察，但没有单项增强机制试验。

6.3 从总体分数到弱类别

D_seed2026 是测试前选定的一份权重，不等于 D 组三种子均值。该模型测试 Accuracy 为 94.87%、Macro-F1 为 0.9290；癌相关间质 Recall 为 62.47%，421 张真实间质图像中识别 263 张，其中 79 张被预测成平滑肌。[S10–S12]



冻结单模型的混淆矩阵。行是真实标签、列是预测；这是图像块结果，不是患者漏诊率。原图：stage5/final/confusion_matrix.png。

AI 可以帮助指出哪些类别值得进一步查看，但不能依据几张图像自动完成病理专家复核。第七阶段还发现高置信预测依然包含错误；这些置信度统计没有被用于训练校准器或确定新的拒识阈值。[S14、S19]

讨论与后续决定

本轮结果的作用是形成可解释、可核查的课程案例。后续没有继续使用已见测试结果进行选择，也不因报告主线转为 AI 而改变科学结论。更广架构、分组交叉验证或量化训练属于另行设计的可能研究，不计入已完成工作。

7 工具封装、GitHub 与复用

7.1 离线演示是独立可使用产物

冻结的 D_seed2026 导出为 FP32 ONNX；独立程序在本地 CPU 读取图像、按固定预处理预测并展示结果。第七阶段记录了 Mac 精简环境、搬迁目录、固定真实样例、异常输入和依赖安装后的断网检查。它不依赖完整训练数据或 PyTorch，但并非无需安装依赖，也没有覆盖所有系统和临床场景。[S17–S18]

7.2 科学来源与教师提交版本分开

原仓库保留阶段一至七的历史事实和固定科学证据。新的教师提交目录只整理当前 PPT、主报告、三份附件、必要源码和证据快照，不是新的模型实验，不修改原仓库。来源表记录复制文件的项目路径、版本和 SHA，避免把后来文稿当成事前协议。[S20–S21]

教师需求	本目录提供的路径
只阅读成果	README → PPT → 主报告 → 附件
核对一个数字或案例	来源索引 → 保存 JSON/CSV/日志 → 对应代码
运行演示	demo 说明 → 校验原 FP32 和样例 → 安装依赖 → 本地预测
完整重训	仅参考原训练入口，须在新环境、新目录另行设计；不是默认验收

独立教师仓库 Wenhow1/pathmnist-ai-practice-submission 已上传，并按小组决定公开。FP32 模型及 10 张固定 PNG 已按原哈希补齐，新副本在 Mac 独立环境完成 20 项检查与 4 项浏览器验收。真实 CI 只查文件和保存结果算术，不执行模型。必要运行资产可从新库获得，无需邀请。PPT 保留可打开的文件与 PDF；现场投影不列为本次要求。[S21]

7.3 实际可复用能力与 Skill 边界

已有 CLI、审计脚本、恢复原型、演示程序和打包逻辑具有复用价值，但并不自动等于正式 Agent Skill。当前没有可追溯的项目专用 local/global Skill 调用记录，因此不列为已使用成果；这也不等于断言所有平台都从未使用任何内部通用能力。提交阶段新增 CI 已有真实通过记录，仅检查文件与保存结果算术，不属于原训练期成果。

7.4 从 ChatGPT 交接包到公开 GitHub 交付

2026 年 10 月 19 日，项目从文稿整理转入发布接手。ChatGPT 会话已形成主报告、附件、PPT、检查器和交接任务包；用户将材料交给已有 Codex 会话，在获授权工作区继续执行。本次没有由 ChatGPT 自动创建新的 Codex 对话或自动派发任务。[S20–S22]

环节	实际衔接
交接	ChatGPT 整理报告、PPT、检查器和执行清单，用户交给已有 Codex 会话
核对与复制	保护原仓库，核对当前文件，仅复制原模型与固定验证样例
新副本验收	独立环境及新目录检查参考输出、异常输入与文件保护
云端与获取	指定提交运行 CI，公开发布附件，再匿名下载核对哈希

Codex 先核对当前目录、原仓库版本及文件哈希，再从既有归档复制 FP32 ONNX 与 10 张固定验证样例。原科学仓库保持保护，新教师仓库承接阅读和交付；不能用旧 ZIP 覆盖已有的新修改，也不把资产复制写成模型重训。

随后在独立 Mac 环境和新目录验收固定样例与异常行为，并推送教师仓库运行云端文件和保存结果算术检查。仓库初建为私有，后按小组决定公开；v1.1.0-teacher 保留了完整材料包、独立演示包与校验值，发布回执记录材料提交、CI 及匿名下载核对。[S21–S22]

新副本检查回答“搬迁后程序能否保持参考行为”，CI 回答“提交文件及保存结果是否符合检查条件”，匿名下载回答“外部读者能否取得同版材料”。本轮 v1.2.0-teacher 只同步文稿与发布过程，不重训或重开官方测试。各层证据共同支持交付，不构成新增临床验证。

8 反思、局限与贡献说明

8.1 本次实践形成的工作方法

第一，任务需要写清目标、上下文、允许的修改范围、输出文件和验收标准。第二，执行应从小到大，代码生成后要运行，运行后要查看独立证据。第三，AI 建议应允许被修正或否决，不能将“更多训练”“更复杂工具”当成默认进步。第四，失败和未覆盖项要留档，最终交付不能靠删除负面结果显得完整。[S02、S08、S13–S17]

这些是本项目过程归纳，不是已量化的教学效果或 AI 效率实验。没有无 AI 对照、精确工时、成本和 token 账本，不能编写节省百分比。

8.2 课程覆盖差异仍需如实保留

事项	本项目实际状态
交叉验证	未做 K 折；缺可靠患者／切片分组 ID；用户决定不追加；无教师豁免记录
指定工具	实际 ChatGPT 对话、Codex 执行与阶段性 DeepSeek 网页；未用 Claude Code
类别不平衡	报告宏平均和逐类指标；普通交叉熵，未做加权或重采样
量化	混合精度通过验证门槛；不是全 INT8，当前 CPU 未加速，无新外测
云端自动检查	原训练期无 Actions 证据；提交期真实 CI 通过，仅查文件与算术
临床与设备	无患者级临床验证；Mac 历史验收不推广为全平台验收

这些差异不会因报告改为 AI 实践主线而自动变成“已满足”。课程原文与实际完成情况应同时呈现。[S01、S14、S21]

8.3 个人与工具贡献

王张文皓（12615035）负责代码与技术实现；赵昱淳（12615027）负责项目规划；李以祺（22615003）负责后端测试与代码整理；朱逸枫（12615026）负责云端维护与报告整理。分工依据小组提供的信息；AI 参与实现与自动执行按日志如实保留，不将未署名的历史操作归给个人，也不编造工时或贡献比例。

责任范围对应资料：王张文皓见代码快照、演示说明；赵昱淳见方法与实验协议、阶段决定；李以祺见源码测试、提交检查说明；朱逸枫见发布接手记录、云端回执。入口仅供定位，不作个人逐条操作署名。

结论

本项目完成了以真实医学图像分类为载体的 AI 辅助工程案例。其价值在于把自然语言任务落实为运行、核查、修复和交付，并能指出每项证据支持到哪里。它既不是新医学算法的声明，也不是“AI 永不出错”的展示，而是一套保留错误、允许否决、重视来源的课程实践过程。

来源导航与提交说明

文内编号供主报告、AI 日志附件与 PPT 交叉引用。完整路径、来源文件 SHA 和范围见本目录 reference/来源编号与阅读索引.md 及 evidence/source_provenance.json。

编号	主要依据
S01	用户提供的课程原始要求
S02–S06	历阶段 AI 日志、方法、数据与训练记录
S07–S09	高分审计、ChatGPT 升级建议核对、独立恢复原型
S10–S12	冻结与正式测试记录、frozen.json、十五条结果表
S13	DeepSeek 原提示、草稿审查与绘图修订
S14–S18	第七阶段 AI 日志、量化诊断、候选结果及演示验收
S19	数据计数及既有 D/E、置信度描述
S20	当前对话中用户确认的改稿与新仓库范围
S21	本提交的文件核查、新副本运行与真实云端发布记录
S22	公开交付过程与本次定向同步依据；详见来源索引

历史来源文件中的“当前”“只在服务器”等措辞描述当时状态；不以它们替代新提交状态。正式数据和权重依然来自原固定实验，本轮未训练、未推理官方测试、未改变结果。发布接手已更新 S21 中的仓库、运行记录和真实 CI 链接；Release 与提交 SHA 以云端回执为准，公开访问以未登录读取回执为准。