研究生工程实践 · PathMNIST · 第一阶段

数据集探索笔记

本笔记整理项目第一阶段的数据探索与第四阶段的关联候选审计。对象是已经发布的 PathMNIST 128 像素图像块，不含新增患者数据。本文的“核验通过”均指所引用阶段的历史记录；本轮不重新打开完整 NPZ 进行数据审计。[E03、E11]

1 数据来源和研究用途

使用官方 pathmnist_128.npz，Zenodo 记录 10519652；MD5 为 ac42d08fb904d92c244187169d1fd1d9。历史准备记录显示完整文件校验通过，保留官方划分和样本顺序。训练与验证来自同一开发来源，测试来自另一临床中心；这属于来源说明，不等于本工程重新查证了每位患者来源。[E02–E03]

项目	数据事实
原始图像	128×128×3，RGB，uint8
标签	整数 0—8，对应九类组织
训练 / 验证 / 测试	89,996 / 10,004 / 7,180 张图像块
任务	组织图像块多分类；非患者诊断 / 生存预测
来源分组	NPZ 未提供患者和原始切片 ID
实际尺寸对照	同一 128 图像直接使用，或缩小到 64；不重新选样本
是否删除或移动样本	精确跨集合重复 0 对；没有因此删改官方划分

2 数据清单如何固定

prepare 流程将图像与标签数组写为可读取的文件，训练以只读内存映射读取图像，减少一次性加载整个数据集的需求。清单记录文件校验值、标签顺序、原始计数、有效索引、重复处理策略和数据标识；后续训练与冻结核对这些身份信息。映射读取是工程方法，不改变样本或标签。[E03]

固定 manifest_id：ce844e66f5f346beccf155173d3de7ed7b161412f65dc6f5d67a347f2b40590b。原文件在服务器目录保存；新增交接资料同时记录既有私有 GitHub 数据 Release。本文不将历史“只在服务器”当成最新存放状态。具体索引见本提交《教师阅读与运行入口》。

研究前已知的限制

不能用 107,180 张图像块代表 107,180 名患者；也不能通过图像索引、文件名或像素哈希自行构造患者 ID。后续若没有可靠分组映射，仍应保留患者级独立性无法核验的表述。

3 九类分布与可视化

ID	组织类别	训练	验证	测试	测试比例
0	脂肪	9,366	1,041	1,338	18.64%
1	背景	9,509	1,057	847	11.80%
2	碎屑	10,360	1,152	339	4.72%
3	淋巴细胞	10,401	1,156	634	8.83%
4	黏液	8,006	890	1,035	14.42%
5	平滑肌	12,182	1,354	592	8.25%
6	正常结肠黏膜	7,886	877	741	10.32%
7	癌相关间质	9,401	1,045	421	5.86%
8	结直肠腺癌上皮	12,885	1,432	1,233	17.17%

表 1 源计数来自 stage1/class_counts.csv；比例为计数/该 split 总数的透明算术。

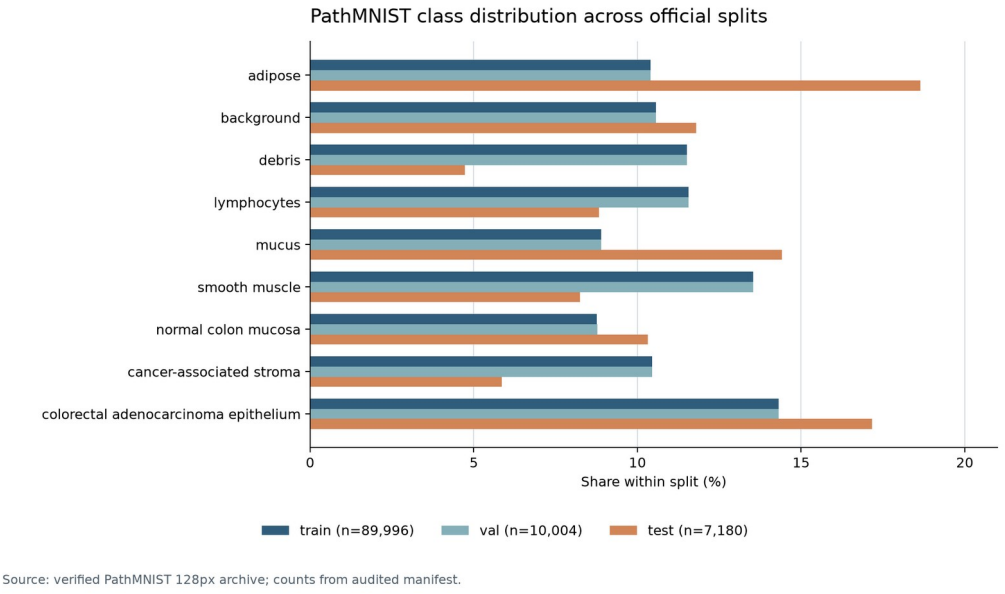


图 1 各 split 内部类别比例。条形长度表示比例，不是患者数量或模型表现。[E03]

训练与验证的类别构成接近，测试构成有变化。例如，标签 0 脂肪在测试中比例较大，标签 2 碎屑较小。由此支持在 Accuracy 之外报告 Macro-F1 和逐类指标，但不能仅凭比例变化推断模型会错在哪里。

项目未增加类别权重或过采样，实际训练仍为普通交叉熵。选择 Macro-F1 是评价层面的等权类别汇总，并不会改变每批图像分布。课程材料提及类别不平衡处理，本文如实说明实际策略与未实施的替代方法，不将其包装成已经完成重采样。[E01、E05–E06]

4 样例与预处理说明

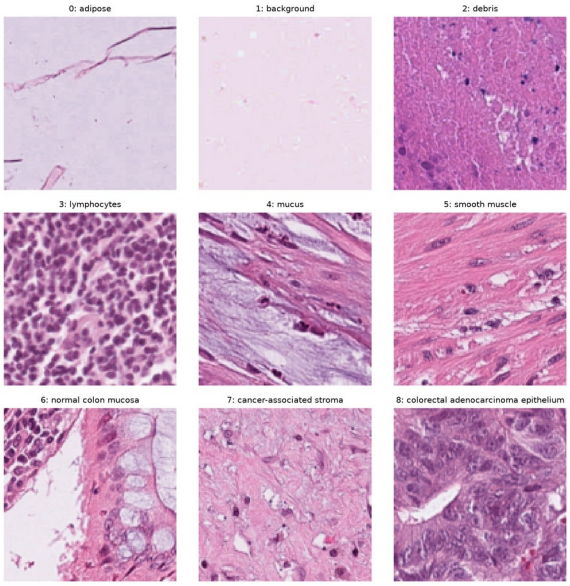


图 2 九类训练样例。标签 0—8 分别对应 train:0、14、9、6、1、3、44、2、5；这些示例不是九名患者。[E03]

样例图只帮助理解输入的外观和标签命名，没有由模型产生新的病理图像，也没有经过专家重新标注。图块中可能包含不同组织成分，本文只沿用数据集给定类别，不凭展示图像改标签或解释疾病进展。

实际预处理顺序

先按运行 size 将图像缩放至 64×64 或 128×128。训练增强开启时，随后随机水平翻转、垂直翻转和 90°整数倍旋转；然后 ToTensor 将图像变为通道优先张量并缩放数值，最后用固定 ImageNet 均值和标准差归一化。验证和测试关闭随机增强。[E03]

单图：H×W×3 uint8 → 3×H×W float 张量

批量：N 张 → N×3×H×W；标签：N 个 0—8 整数

H=W=64 或 128；N 是本批图像数量。D 组完整批量 N=128，末批可更小。标签另交给训练损失或评价函数，并不拼进图像。固定数值归一化没有学习患者信息，也不是染色域适配。

5 完整性与近重复审计

步骤	历史检查结果	仍不能推出的结论
文件与数组	MD5 及六个数组/索引 SHA 记录；形状、标签、计数通过	不能由文件完整性证明病理标签全无噪声
精确跨集合重复	完全像素一致 0 对	不能排除变换图、相邻图块或同患者关联
开发集候选筛查	9,032 哈希候选对；849 满足像素阈值	不能称 849 次患者泄漏
涉及图像	91 个不同验证索引：背景 80、碎屑 2、平滑肌 9	一个验证图可匹配多个训练图，候选对数不能当图像数
排除敏感性	B/D 六次候选内均无误判；F1 均值变化 <0.000003	不足以直接解释高分，不证明不存在未检出的关联

候选方法使用 8×8 灰度平均哈希及汉明距离，再考虑四种旋转及翻转对齐，对块均差和完整像素差筛选。初版对齐方向选择不充分，修订并重跑后采用最终结果。筛查可能漏掉平移、裁剪、染色差异和更远的来源关联，因此没有凭启发式阈值自动删除或移动官方样本。[E11]

最相近的一对对齐后像素均差约 0.2077/255，RGB 通道值 97.89%一致，但官方图像名不同。独立图像名只说明映射没有指向同一名称，不是切片或患者隔离证明。来源映射抽查保留了具体 split/index，不将名称重新编码为患者 ID。

审计结论

在所检查的工程层面，没有发现训练/验证数组混用、随机增强进入验证、评估模式错误、标签错位或指标误算。近似候选不足以直接解释整体高分，但完整患者级独立性仍未获得。保持官方划分，并将验证与另一中心测试分别报告，是当前资料支持的处理方式。

6 数据产物与报告引用

文件 / 目录	供什么问题追溯
stage1/manifest.json	数据身份、原始和有效计数、索引校验与限制
stage1/class_counts.csv	九类数量及比例
stage1/sample_provenance.json	样例图的 split/index 来源
stage1/cross_split_duplicates.csv	精确跨集合重复处理明细；当前为空记录
pathmnist_project/data.py	下载、解析、只读读取、预处理与增强限制
stage4/audit/高验证分数来源审计.md	数据/评估管线及候选方法说明
stage4/audit/near_duplicate_scan.json	候选计数、图像索引和像素阈值结果
stage4/audit/candidate_sensitivity.json	排除候选后的保存概率复算
data/release_manifest.json	资料包保存的既有私有数据 Release 入口

上表是数据来源与探索的归档入口，不是要求重新运行准备或删除样本。全部路径按固定项目根理解；新版交付位置另见资料导航快照。正文中的[E 编号]沿用技术评估附件的原证据索引；对应文件已在本提交的来源快照中整理。

本次交付的范围

本笔记作为 AI 工程实践主报告的数据附件：它单独呈现课程要求中的“数据集探索”，不冒充患者队列研究或临床数据清洗。真实组员、学号、个人贡献待小组填写。项目已决定不补 K 折和 QAT；未做 K 折仍作为事实记录，不推断教师已经豁免。

整理采用用户新增资料包、旧 v2 包和 PPT 素材包中的现存图像与源表。本轮只进行文档编排、文件和简单数值检查，没有模型推理、完整 NPZ 重审或新统计显著性试验。

数据集选择中的 AI 交互与核查分工

本页新增的是历史过程的归纳，不是重新选择数据集或重新下载数据。用户先确定医学图像方向，助手推荐 PathMNIST；随后以课程条目、官方来源、数据结构和任务规模核对适用性。没有多数据集效果海选记录，不补写虚构筛选分数。[S01–S04]

环节	任务输入与 AI 产物	核验方法	人的约束／仍需确认
选择方向	医学图像方向；AI 说明 PathMNIST 九分类	对照课程 MedMNIST 条目和已归档来源	用户确认任务；不冒充新病理诊断数据
下载与整理	在指定服务器目录建立数据清单	MD5、数组、标签和索引检查	只操作本人目录，不下载完整数据到本机
数据探索	生成九类样例和分布图	源计数、样例索引、图表检查	AI 目视检查不是专家重新标注
高分质询	近重复候选与敏感性统计	启发式相似度、已有概率复算	不把候选定性为患者泄漏，不自动删样本
报告解释	AI 整理来源与边界	对照数据包实际字段	无患者 ID，不能把索引写成患者分组

数据清单解决“后续使用的是否同一份数据”，来源说明解决“数据是什么及能回答什么”。这两类核对互相补充，不能用哈希正确代替医学或患者层面的判断。

当前没有重新运行完整 NPZ 审计；以上通过情况均引用历史证据。具体代码见 technical/source_snapshot/pathmnist_project/data.py，阶段原件见 evidence/source/stage1 与 stage4/audit。