AI 工程实践 · 交互与核验附件

AI 使用日志与交互案例

本附件以保存的阶段 AI 日志、原始提示、源码审阅和验收记录为依据，说明人怎样把任务交给 AI，怎样处理其输出，以及哪些内容未被采纳。它不是完整聊天逐字导出，也不补画不存在的聊天截图。原件均保留在 evidence/source；文中 S 编号见 reference/来源编号与阅读索引.md。

1 记录分类与使用原则

标记	含义	使用方式
原话节选	能在保存的日志／当前对话中定位的文字	使用引号或引用块，注明来源，不伪装成整段完整会话
日志摘要	根据阶段记录整理的任务与响应	不加“原始提示词”标签，不推测未记录上下文
源码事实	从指定代码或配置直接可见	说明文件和作用，不等于新运行
历史实测	原命令、日志、指标或设备验收	保留时间和环境范围，不称本轮复跑
本轮整理／新增检查	当前文稿、目录与静态校验工具	与历史模型成果分开；云端执行需真实记录

实际工具角色

ChatGPT 参与对话、方案讨论、交接、材料解释和提交组织；Codex 承担大部分仓库、终端、训练与验证实现；DeepSeek 网页仅有第六阶段风险审查及草稿记录。项目未使用 Claude Code。不同 AI 的相互审查不是自动的独立实验认证。[S02、S08、S13–S14]

当前连接不具备创建 Codex 会话或 GitHub 写入动作；因此本轮没有“自动创建 Codex 任务成功”的记录。后续需用户在有权限的工作区启动一次交接，具体任务与文件已准备。

2 从选题到交付的阶段日志

阶段	输入任务与约束（摘要）	AI 产物及执行	核查／取舍
选题	医学图像方向；子集由助手推荐	PathMNIST 任务、数据与对照建议	未记录多数据集性能海选
数据环境	只在本人服务器目录；不在本机下载完整数据	环境、数据下载、manifest、分布图	MD5 与数组检查；患者 ID 限制保留
流程基线	分阶段开展，每阶段留汇报证据	smoke、probe、run-one	先小后大；共同 batch128 可用
A—D	同一协议继续剩余主实验	11 次新轨迹及既有基线；逐图复核	三种子不是三折；未打开正式测试分数
审计扩展	查高验证分数；完成 E；恢复原型独立开发	候选审计、三条 E、resume_v2	不自动删近同样本；不扩满建议训练
冻结测试	锁定后评价；不覆写既有证据	D_seed2026 选择、15 条统一测试	E 更高也不倒改本轮选择
量化	冻结后仅 train 校准、val 验收	DeepSeek 草稿、Codex PTQ 与图表	原两版失败记录保留
第七阶段	不重训、不重开测试、独立演示与补证据	原 CSV 复制核验、CLI/UI、有限 PTQ	候选通过精度门槛仍更慢，默认 FP32
当前提交	AI 实践为主，原仓库不动，新仓库独立	新主报告、附件、同步 PPT、提交目录	云端创建与 CI 尚待执行，不回写历史

以上是工作流摘要，不把所有代码生成和执行归为同一次提示。主要来源：S02、S05–S10、S13–S14、S20。

阶段衔接

阶段总结不是单纯“完成百分比”，而应说明产物路径、核验结果、未决问题与下一步是否得到批准。用户多次提出范围和不覆盖约束，Codex 再依据当前源码与产物落实；由此把聊天中的意图保存在项目文件中。

3 案例一：把方向描述变成明确任务

原话与摘要分开

阶段日志保存的用户原话节选：

可以，进行下一阶段的任务了，要在每一阶段做好记录，最终目的都是为了最后的汇报和报告。

来源：docs/AI 使用日志.md，第二阶段条目。[S02]

“选择医学图像方向，将具体子集交由助手推荐”属于同一日志中的人工决策摘要；它不是本附件重新取得的一段完整原始聊天。此处不用虚构的聊天气泡展示。

AI 如何拆解

任务从领域方向细化为 PathMNIST 数据、九类标签、官方划分、模型与尺寸比较、D/E 消融、种子、训练设置、评价指标和冻结规则。相应产物是方法协议、matrix、manifest、代码及阶段文档。配置形成经历多轮推进，不应声称“一句提示自动生成最终全部设计”。[S02–S06]

原始约束的工程作用

约束	落到文件或执行上的作用
只使用本人项目目录	环境、下载缓存和运行输出限定在约定项目范围
不把完整数据下载到本机	大数据与权重留在服务器，轻量证据另行复制
每阶段保留记录	保存命令、日志、配置、来源标识与图表
先检查再扩大	小样本测试不能省略，也不能将其分数并入正式实验

后来当用户允许数据在服务器下载或调整运行范围时，记录注明了授权变化，没有把最初限制当成永远不变，也没有无依据推断新的授权。

可以从这个案例学到什么

有效交互不仅包含目标，还应给出上下文、边界和验收方式。字段如何固定、图像尺寸如何选择仍需要在后续实现中检查；任务文档不是正确性的替代品。

4 案例二：ChatGPT 建议由 Codex 回到源码核对

日期与性质： 2026-09-23；方案评审，不是新增实验启动。用户把 ChatGPT 对话中的 PATHMNIST_EXPERIMENT_V2.md 与 CODEX_START_HERE.md 交给 Codex，并要求判断建议是否适用。原建议正文在本附件中不重建，仅引用已归档审阅表。[S08]

对话中的建议	源码／协议核对	采纳状态与证据
需要补自动早停	已有验证 Macro-F1 早停	否决“缺失”判断，不重复实现
需要完整断点恢复	best.pt 缺优化器、调度器、随机状态	采纳，但在独立 resume_v2 目录实现
40 轮直接续到 200 轮	T_max 变更影响学习率轨迹	不当原训练延续；未默认启动
更多轨迹与新的增强消融	建议参照不等于原 E 组	先完成原协议，不照搬建议预算
高分值得核查	数据与代码审计具有实际价值	采纳只读审计，保留患者 ID 限制

实际恢复原型有本地合成检查及历史 GPU 短轨迹验收；连续 4 轮与 2+2 恢复的 24 项状态比较一致。它不构成第四个种子或新的正式模型结果。[S09]

对协作的影响。 ChatGPT 可以帮助提出结构化方案，但执行代理必须掌握当前代码状态；Codex 的核对也要留下依据。这个案例避免了把另一对话的假设直接转成大量新增训练。

未确认个人归属。 日志记有用户提出审阅任务、Codex 完成审阅与实现；没有署名证据的逐行人工审核，不归给具体组员。

5 案例三：DeepSeek 审查和草稿的选择性采用

日期： 2026-09-28。实际界面为 DeepSeek 网页。输入为公开方法概述，不上传完整源码、原图、逐图预测、服务器地址或凭据。[S13]

原始提示节选

请给出：1）按严重性排序的最多 6 个实施或解释风险及相应验收办法；2）一段不超过 50 行的 Python 函数，接收相同顺序的 y_true、FP32 九类概率数组和 INT8 九类概率数组，验证形状/有限值/概率和……请只依据上述公开方法信息回答，不假设你已运行该项目。

省略处仅为缩短显示，完整原话见原记录。函数接口、数据角色与不使用测试集调参等条件也在原提示中说明。

反馈与处理

DeepSeek 提出校准和验收集分工、S8S8 数值风险、计时可比性、概率接口、校准采样偏差和逐类退化等风险。指标草稿存在输入检查不完整：0—8 标签、非负概率、非空样本和固定九类 labels 未完整约束。该函数未进入正式指标管线，沿用已有 classification_metrics。[S13]

第二次提示请求从 comparison.json 生成对比图，不访问网络和原图。草稿经过协议、非法数值、P95、文字位置及字体修订后，先用合成 JSON 验收。合成数据图不用于正式结果，正式图来源为真实量化汇总。

结论。 AI 草稿可以被拒绝；两个不同工具参与，不等于自动获得两份实测证据。“人工修订”没有具体署名的部分保持待确认，不写成某位组员完全独立实现。

6 案例四：复核脚本失败，只修复核验链条

第五阶段模型已经产生正式测试预测，独立复核程序首次读取混淆矩阵时，将 JSON 列表误当对象，导致程序停止。修复的是读取类型，再重新运行复核脚本；正式测试预测没有重跑或修改。[S10]

需要区分	此次实际对象
原始实验产物	冻结模型已生成的测试预测与指标
出错程序	读取和比较这些产物的独立复核脚本
修复范围	JSON 类型处理
重跑范围	复核脚本，而非模型训练或测试预测
最终证据	修复后的核查记录与原结果来源仍一致

如果因为核验程序报错就重新生成测试预测，既不能直接解决类型问题，还可能覆盖原证据。保留失败和控制修复范围，是 Harness 在真实工程中的具体作用，而不是要求系统永远不出错。

关联案例：演示路径与文件保护

第七阶段把依赖原服务器路径的演示整理为独立 CLI/UI，默认 FP32，检查模型 SHA、标签、布局与预处理，限制路径越界，输出使用拒绝覆盖的方式。已有搬迁目录、断网与异常输入记录，但不等于当前新教师目录已经包含模型、样例或完成运行。[S17–S18、S21]

7 案例五：量化诊断、重试与证据边界

任务摘要。 第七阶段要求限时、只用 train/val 诊断，若有明确线索才有限追加 PTQ，不打开官方测试，不自动 QAT。[S14–S15]

问题与修复顺序

问题	处理	没有做的事
reader 缺迭代接口	修订数据读取，保留失败退出码	不删除失败记录
uint8 调试助手计算回绕	提升类型并用反量化对照复核	不认定其为实际 ONNX 推理失败根因
原量化分数严重下降	根据训练样例线索登记五 Conv 浮点候选	不用测试集挑量化参数
初次候选验收基线路径错误	对照候选 SHA，修正路径后再核验	不将启动成功当完整验收成功
候选精度恢复、速度仍慢	保存候选与各自基线，默认 FP32	不把压缩率改称加速率

历史记录区分 18 张独立诊断样例、576 张训练校准样例与 10,004 张验证图像；含重试的验证处理张次不等于更多独立样本。完整验证 F1 为 0.9956677882，现存记录为工程验收，未形成新外部测试。[S15–S16]

为什么保留失败也有报告价值

本案例允许看到输入接口、辅助工具、数据路径和性能目标四类问题；它们需要不同检查，不能统一称为“模型不够好”。本轮重新组织材料没有重新执行上述命令，历史验收和当前文稿检查分开。

8 Skill、复用与新提交阶段

8.1 实际记录与不能补造的内容

项目已存在的数据/训练 CLI、审计脚本、resume_v2、portable_demo 和打包逻辑，是可复用的工程能力。当前没有专用 local/global Skill 名称、配置作用域与调用记录的完整证据，因此不列为项目历史已使用的正式 Skill 包。[S02、S14]

对本轮文稿制作而言，使用的文档／PPT 渲染工具和本地文件检查属于当前整理行为，不倒写成训练期的 Codex Skill。将来新增 Skill，应记录名称、版本、作用域、触发任务与实际输出，而非仅截图“已安装”。

8.2 新教师仓库的边界

用户已确认原科学仓库保持不变，新建独立私有提交仓库。本轮已准备源码与必要证据快照、新报告和 PPT、核查脚本及 CI 配置；没有接口可直接建立 Codex 对话或写入 GitHub。云端仓库、Release、CI 和教师访问状态仍待执行，见 S21。没有把“生成 workflow YAML”写成“GitHub Actions 通过”。[S20–S21]

8.3 个人贡献待填

成员	学号	实际做过的任务	可定位文件／交互	本人确认
王张文皓	待填	待按真实参与填写	待填	待确认
赵昱淳	待填	待按真实参与填写	待填	待确认
李以祺	待填	待按真实参与填写	待填	待确认
朱逸枫	待填	待按真实参与填写	待填	待确认

姓名来自用户上传 PPT，不能据角色表自动推测各成员完成了数据处理或程序开发。没有完整工时／token 基线，不报告虚构的节省数值。

原件与来源

主要原件：docs/AI 使用日志.md；docs/实验升级方案审阅记录.md；stage4/续训工程验收记录.md；stage5/第五阶段执行记录.md；stage6/DeepSeek 量化审查记录.md；stage7/AI 使用日志.md、执行记录.md、quantization_diagnosis.md。复制路径及 SHA 见 evidence/source_provenance.json；本轮决定见 ai_workflow/decisions/本轮用户决定.md。